SemEval-2027 Task 5 (ComPartMent) – Subtask A English: Hướng tiếp cận & Kế hoạch

Nov 2, 2026 · @Thái

Tóm tắt

Task 5 là **ComPartMent**: với mỗi câu chứa một noun compound, hệ thống cho hai điểm 0–5 về mức compositional của modifier và của head. Hướng đề xuất là tách bài toán thành mức type (cả compound) và độ lệch theo từng câu, rồi gộp nhiều nhánh bằng stacking.

- **Dữ liệu EN-NN:** 444 compound / 3.480 câu để train; 116 compound / 908 câu để test; compound ở test không xuất hiện trong train.
- **Cách chấm:** metric chính là Spearman giữa dự đoán và trung bình điểm người chấm; metric phụ phạt việc cho mọi câu của một compound cùng một điểm.
- **Nhận định then chốt (cần tự kiểm chứng):** phần lớn metric chính nhiều khả năng đến từ việc xếp đúng các compound với nhau, nên một prior mức type tốt là bắt buộc.
- **Baseline:** B0 hằng số/oracle → B1 cosine tĩnh → B2 BERT không giám sát → B3 DeBERTa fine-tune → B4 LLM zero-shot.
- **Hướng đề xuất:** Đ1 prior + độ lệch, Đ2 loss bám metric, Đ3 định nghĩa/WiC, Đ4 LLM chấm theo nhóm câu, Đ5 stacking, Đ6 bền vững với văn bản lịch sử.
- **Mốc:** chốt pipeline Dec 31, 2026; đánh giá chính thức Jan 10, 2027 – Jan 31, 2027; nộp system paper tháng 2/2027.

Việc làm ngay tuần này: viết evaluator đúng 3 metric, làm EDA, và cố định bộ chia GroupKFold theo compound.

1. Bài toán và cách chấm điểm

Subtask A yêu cầu xếp hạng các câu theo mức compositional của modifier và của head; mỗi câu nhận hai điểm thực trong khoảng 0–5. Ban tổ chức là Filip Miletić, Chris W. Jenkins và Sabine Schulte im Walde (ĐH Stuttgart) — xem trang task và Codabench.

Ví dụ của BTC: *flea market* trong một câu có Mod 0.0, Head 4.7, tức *flea* gần như mất nghĩa gốc còn *market* giữ nguyên nghĩa. *firing line* dùng theo nghĩa bóng có Mod 0.6, Head 0.7. Subtask B (particle verbs) và dữ liệu tiếng Đức nằm ngoài phạm vi của nhóm.

Dữ liệu tiếng Anh, noun compounds

Phần	Compound	Câu	Ghi chú
Trial (5/9/2026)	2	10	Chỉ để thử định dạng; không thuộc train/test
Train (8/9/2026)	444	3.480	Có ModAvg, ModStd, HeadAvg, HeadStd
Test (10/1/2027)	116	908	Không có nhãn; không cho biết câu hiện đại hay lịch sử

- Mỗi compound có tối đa 10 câu: 5 câu hiện đại và 5 câu lịch sử; ít hơn khi dữ liệu lịch sử thưa (trung bình khoảng 9 câu).
- Train/test chia 80/20 theo compound, sau khi chia bin theo mức compositional để giữ phân phối điểm.
- Cột dữ liệu: `ContextID`, `Compound`, `Mod`, `Head`, `ModAvg`, `ModStd`, `HeadAvg`, `HeadStd`, `Context`.
- File nộp: một zip chứa `en-nn-pred.tsv`, không header; mỗi dòng gồm `ContextID`, điểm Mod, điểm Head, phân cách bằng tab.

Ba metric

Metric	Cách tính	Vai trò
Compositionality correlation	Spearman giữa dự đoán và gold trên mọi câu của một thiết lập	Chính
Context variance correlation	Lấy std của dự đoán qua các câu của từng compound, rồi tính Spearman với std tương ứng của gold trên tập compound	Phụ
RMSE	Căn của trung bình bình phương sai số	Bổ sung

Mỗi metric tính riêng cho từng thiết lập (en-nn Mod và en-nn Head); BTC báo cáo thêm trung bình qua các thiết lập. `ModStd` / `HeadStd` là độ bất đồng giữa người chấm trong một câu, không phải std dùng cho metric phụ.

Lịch: đánh giá chạy 10–31/1/2027; system paper nộp tháng 2/2027, thông báo tháng 3, camera-ready tháng 4, workshop mùa hè 2027 (lịch chung SemEval-2027, thông báo Task 3 cùng đợt).

Định nghĩa metric và định dạng nộp lấy từ bản lưu trang Overview của Codabench (lưu ngày 22/10/2026) do mình không đọc trực tiếp được trang Codabench; hãy đối chiếu lại trên Codabench.

2. Bảy điều phải kiểm chứng trước khi làm mô hình

Bảy đặc điểm dưới đây quyết định thiết kế hệ thống, nên kiểm chứng chúng trên dữ liệu train ngay tuần đầu. Mục 1, 2 và 5 dựa trên phân tích của một repo công khai của đội khác, chưa được BTC xác nhận.

1. **Điểm số tập trung ở mức type.** Repo trên báo cáo: gán cho mọi câu trung bình gold của compound cho metric chính khoảng 0,70–0,92 trên các thiết lập của task, nhưng metric phụ thành NaN. Làm gì: tính tỷ lệ phương sai giữa/trong compound (ICC) cho Mod và Head; nếu cao, đầu tư mạnh vào prior mức type.
2. **Metric phụ phạt dự đoán hằng số.** Nếu mọi compound có std dự đoán bằng 0, metric phụ không xác định; nếu chỉ một phần compound bị "sập", điểm tụt mà không báo lỗi. Làm gì: luôn theo dõi số compound có std dự đoán bằng 0.
3. **Nhãn có nhiễu.** Gold là trung bình nhiều người chấm, kèm độ lệch chuẩn từng câu, nên trần thực tế của metric thấp hơn 1. Làm gì: dùng `ModStd` / `HeadStd` để đánh trọng số mẫu hoặc làm nhãn mềm (Đ2).
4. **Khoảng một nửa là câu lịch sử.** Chính tả và văn phong cũ gây lệch miền, trong khi test không cho biết thời kỳ. Nghiên cứu của nhóm BTC chỉ thấy compositional giảm nhẹ theo thời gian (Jenkins et al., 2026). Làm gì: gắn nhãn thời kỳ suy đoán để phân tích lỗi (Đ6).
5. **Có thể có rò rỉ theo thứ tự `ContextID`.** Repo trên báo cáo thứ tự ID trong một compound tương quan rất mạnh với điểm ở một số tập. Làm gì: kiểm tra trên en-nn; không dùng ID hay thứ tự dòng làm đặc trưng; nếu xác nhận, báo BTC thay vì khai thác.
6. **Không có dev set, compound ở test là mới.** Làm gì: dùng GroupKFold theo compound. Trước khi dùng dữ liệu ngoài (90 compound của Reddy, 280 compound của Cordeiro/NCTTI), kiểm tra trùng compound và hỏi BTC về quy định.

7. **LLM có thể đã thấy dữ liệu.** Câu lịch sử lấy từ văn bản công khai; Kurtyigit et al. (2025) cũng lưu ý ChatGPT có thể đã thấy bộ Reddy. Làm gì: thêm phép thử contamination khi dùng LLM (Đ4).

3. Các hướng tiếp cận hiện có (kèm paper)

Tài liệu liên quan chia thành chín hướng; với bài toán theo ngữ cảnh này, mạnh nhất là mô hình fine-tune theo câu kết hợp tín hiệu mức type và LLM. Cột cuối cho biết hướng đó được dùng ở baseline (B) hay hướng đề xuất (Đ) nào.

Hướng	Ý tưởng cốt lõi	Paper	Phát hiện đáng chú ý	Dùng ở
H1. Distributional tĩnh	Cosine giữa vector compound và vector từng thành phần	Reddy et al. 2011; Salehi et al. 2015; Cordeiro et al. 2019	Skip-gram vẫn mạnh: ρ ≈ 0,57 cho cả Mod và Head trên 88 compound của Reddy (Kurtyigit et al. 2025)	B1, prior Đ1
H2. BERT không fine-tune	Rút đặc trưng từ embedding ngữ cảnh, so compound với thành phần	Miletić & Schulte im Walde 2023; khảo sát TACL 2024; Miletić & Schulte im Walde 2025	Chỉ tốt khi cấu hình rất kỹ; thông tin nằm ở các layer đầu; Mod và Head hành xử khác nhau; tần suất, độ đa nghĩa, năng sản ảnh hưởng kết quả	B2, đặc trưng Đ1
H3. Đánh giá theo token	Chấm compositional cho từng lần xuất hiện trong câu	Garcia et al. 2021 (NCTTI); Shwartz & Dagan 2019	NCTTI có 280 compound tiếng Anh với 8.725 nhãn mức token, tương quan mạnh với nhãn type; mô hình ngữ cảnh chưa bắt được idiomaticity như người	Dữ liệu phụ trợ, Đ3

Hướng	Ý tưởng cốt lõi	Paper	Phát hiện đáng chú ý	Dùng ở
H4. Fine-tune cross-encoder	Hồi quy điểm trực tiếp từ câu đã đánh dấu span	SemEval-2022 Task 2 (bài toán gần: idiomaticity theo ngữ cảnh); repo công khai	Repo báo DeBERTa ≈ 0,46 (Mod) / 0,38 (Head) trên en-nn, split nội bộ, không chính thức	B3, nền Đ1–Đ3
H5. WiC / usage similarity	Nhúng riêng từ đích trong câu để so hai cách dùng	XL-LEXEME (Cassotti et al. 2023)	Bi-encoder huấn luyện trên WiC, mạnh cho phát hiện đổi nghĩa	Đ3
H6. LLM chấm điểm	Prompt LLM cho điểm trực tiếp, hoặc sinh định nghĩa rồi so	Kurtyigit et al. 2025; G-Eval; COGNAC và SwanNLP tại SemEval-2026 Task 5	ChatGPT đạt ρ ≈ 0,74 trên Reddy nhưng có thể đã thấy dữ liệu; điểm kỳ vọng theo xác suất token tránh hòa điểm; ở task chấm 1–5 năm 2026, comparative prompting + ensemble LLM vào top 4 (ρ 0,83), GPT-4o few-shot động đạt 0,755, Qwen 4B fine-tune chỉ 0,491	B4, Đ4
H7. Học từ bất đồng, tối ưu xếp hạng	Dùng phân bố điểm người chấm; loss xấp xỉ Spearman	Uma et al. 2021; Blondel et al. 2020	Nhãn mềm có lợi khi mỗi mẫu có nhiều người chấm tốt; xếp hạng khả vi chạy O(n log n)	Đ2

Hướng	Ý tưởng cốt lõi	Paper	Phát hiện đáng chú ý	Dùng ở
H8. Diachronic	Theo dõi compound và thành phần qua các thập kỷ	Jenkins et al. 2026; Mahdizadeh Sani et al. 2024; Dhar et al. 2019	Compositional chỉ giảm nhẹ theo thời gian; mô hình học trên lát thời gian hẹp khớp tốt hơn; vector tĩnh cạnh tranh với ngữ cảnh	Đ6
H9. Đa phương thức	Sinh ảnh cho compound và thành phần rồi so ảnh	Kurtyigit et al. 2025; Godbersen et al. 2026 (ComposiGen)	Ảnh bổ sung cho text (0,62/0,59 so với 0,57/0,57 chỉ text); late fusion đơn giản thắng mô hình đa phương thức	Hướng tương lai

BTC nhấn mạnh tính mới của task: chấm ở mức token, hai loại MWE, hai ngôn ngữ và dữ liệu lịch sử. Khoảng trống paper của nhóm có thể nhắm tới là cách kết hợp prior mức type với mô hình theo câu, và mức độ LLM bị contamination trên câu lịch sử.

4. Giao thức đánh giá nội bộ

Mọi thí nghiệm dùng chung một bộ chia theo compound và một evaluator tái hiện đúng 3 metric chính thức; không có hai điều này thì mọi so sánh đều vô nghĩa.

- **Chia dữ liệu:** `StratifiedGroupKFold` 5 fold, nhóm theo `Compound`, phân tầng theo bin của trung bình ModAvg (giống cách BTC chia); lặp 3 seed, báo cáo trung bình ± độ lệch chuẩn.
- **Evaluator:** Spearman bằng `scipy.stats.spearmanr` (xử lý điểm hòa đúng cách); metric phụ = Spearman giữa std theo compound của dự đoán và của gold; RMSE. Tính riêng Mod, Head, rồi lấy trung bình.
- **Kiểm tra trên Codabench:** nộp thử dữ liệu trial để xác nhận định dạng, metric chính và RMSE. Trial chỉ có 2 compound nên không kiểm tra được metric phụ.
- **Chỉ số chẩn đoán:** ρ giữa compound (tính trên trung bình theo compound), ρ trung bình trong từng compound, số compound có std dự đoán bằng 0, ICC của gold.

- **So sánh hệ thống:** bootstrap theo compound (1.000 lần) để có khoảng tin cậy 95%; chỉ giữ một cải tiến khi nó vượt dao động giữa các seed.
- **Lưu trữ:** lưu dự đoán out-of-fold (OOF) của mọi mô hình để stacking (Đ5); ghi config, seed, commit của từng lần chạy vào một file log chung.

5. Baseline (B0–B4)

Năm baseline tăng dần độ phức tạp; B3 là baseline mạnh mà mọi hướng đề xuất phải vượt qua có ý nghĩa thống kê.

Mã	Hệ thống	Mục đích	Tài nguyên
B0	Hằng số (trung bình train); "type oracle" gán trung bình gold của compound, chỉ để phân tích, không nộp	Mốc sàn; đo phần điểm đến từ mức type	CPU
B1	Cosine vector tĩnh (word2vec/fastText) giữa compound và từng thành phần, hiệu chỉnh tuyến tính về 0–5	Prior mức type kinh điển (H1); metric phụ sẽ NaN vì mỗi compound chỉ có một giá trị	CPU
B2	BERT/RoBERTa không fine-tune, các layer đầu: cos(thành phần trong câu, compound trong câu) và cos(thành phần trong câu, "nguyên mẫu" của thành phần khi đứng một mình)	Tín hiệu theo câu, không giám sát (H2)	GPU 16 GB
B3	DeBERTa-v3 base/large fine-tune hồi quy 2 đầu ra, đánh dấu span bằng thẻ, loss MSE	Baseline mạnh có giám sát (H4)	GPU 16 GB
B4	LLM mở 7–9B zero-shot, có định nghĩa thang điểm; điểm = kỳ vọng theo xác suất các token 0–5	Năng lực LLM khi chưa huấn luyện (H6)	GPU 16 GB, lượng tử hóa 4-bit

- **B1:** vector tĩnh cho cả compound (như *flea_market*) thường không có sẵn; cần tự huấn luyện trên corpus đã nối compound, hoặc thay bằng trung bình embedding ngữ cảnh.
- **B3:** đầu vào dạng `... our <m>flea</m> <h>market</h> will ... [SEP] flea market`; hai đầu ra qua 5 × sigmoid để nằm trong 0–5.

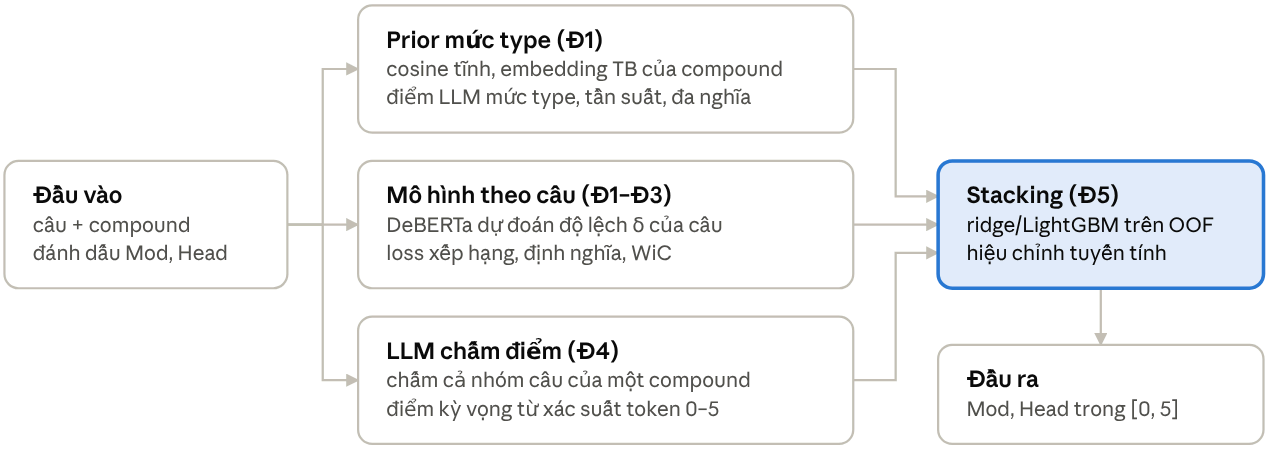
- **B4:** prompt gồm định nghĩa Mod/Head, hai ví dụ neo thang điểm của BTC, câu cần chấm; yêu cầu trả một chữ số rồi lấy xác suất của 6 token.

6. Hướng đề xuất (đóng góp cho paper)

Hệ thống chính gồm prior mức type cộng độ lệch theo câu, thêm tín hiệu định nghĩa/WiC và LLM, rồi gộp bằng stacking. Mỗi khối là một đóng góp đo được bằng ablation.

Ba nhánh dự đoán độc lập, gộp bằng stacking

Nhánh 1 nhắm vào xếp hạng giữa các compound; nhánh 2 và 3 thêm biến thiên theo từng câu



kiến trúc hệ thống · 3 nhánh, 1 tầng stacking

Ba nhánh chạy độc lập trên cùng bộ chia CV; stacking chỉ học trên dự đoán OOF của chúng nên không rò nhãn.

Đ1. Prior mức type + độ lệch theo câu. Dự đoán $\hat{y}$(câu) = p(compound) + δ(câu): p cho biết compound mới này compositional đến đâu, δ cho biết câu này lệch lên hay xuống.

- p: hồi quy trên đặc trưng mức type — cosine tĩnh (B1), trung bình embedding của compound trên mọi câu của nó (kể cả câu test, vì không dùng nhãn), điểm LLM mức type, tần suất và số nghĩa WordNet của thành phần.
- δ: cross-encoder học nhãn đã trừ trung bình compound ($y - \bar{y}$ của compound); gộp p và δ bằng phép cộng hoặc hồi quy.
- Giả thuyết: p kéo metric chính nhờ xếp đúng giữa các compound; δ kéo metric phụ nhờ chuyên trách biến thiên trong compound.
- Cơ sở: kết quả type oracle (mục 2); nhãn token tương quan mạnh với nhãn type (Garcia et al. 2021); đặc trưng compound–ngữ cảnh từ BERT (Miletić & Schulte im Walde 2025).

Đ2. Loss bám metric và học từ bất đồng.

- Loss = MSE + λ · soft-Spearman trong batch (Blondel et al. 2020) + μ · ranking theo cặp giữa các câu cùng compound.
- Sampler theo nhóm: mỗi batch chứa trọn các câu của vài compound để loss trong compound có nghĩa.
- Trọng số mẫu theo 1/(Std² + ε), hoặc Gaussian NLL với `ModStd` / `HeadStd` làm độ bất định (Uma et al. 2021).
- Giả thuyết: loss xếp hạng tăng metric chính; ranking trong compound tăng metric phụ; trọng số theo bất đồng giảm ảnh hưởng của nhiễu.

Đ3. Bổ sung tri thức: định nghĩa, paraphrase, WiC.

- Nối vào đầu vào định nghĩa của Mod và Head (WordNet hoặc LLM sinh), cùng một paraphrase theo câu do LLM sinh: "*ở câu này, flea market* nghĩa là …".
- Đặc trưng XL-LEXEME: độ tương đồng giữa cách dùng thành phần trong compound và các câu tham chiếu nơi thành phần đứng một mình.
- Đặc trưng thay thế: thay compound bằng head hoặc bằng paraphrase, đo thay đổi embedding của câu (hướng của Garcia et al. 2021).
- Cơ sở: prompt kiểu định nghĩa/kịch bản tốt hơn hẳn chỉ đưa từ (Kurtyigit et al. 2025); XL-LEXEME (Cassotti et al. 2023).

Đ4. LLM chấm theo nhóm câu + tinh chỉnh LoRA.

- Comparative prompting: đưa cùng lúc mọi câu của một compound, yêu cầu chấm Mod/Head cho từng câu; lấy điểm kỳ vọng theo xác suất token (G-Eval).
- Few-shot động: chọn các ví dụ train gần nhất theo embedding làm minh họa.
- Ensemble nhiều prompt × nhiều model mở; thêm model API nếu có kinh phí và được luật cho phép.
- LoRA/QLoRA một LLM 3–8B: dự đoán phân bố trên 0–5 rồi lấy kỳ vọng.
- Contamination probe: cho LLM viết tiếp nửa sau của câu lịch sử; so hiệu năng giữa câu "đã thấy" và "chưa thấy".
- Cơ sở: ở SemEval-2026 Task 5, comparative prompting và ensemble cải thiện rõ; LLM lớn few-shot vượt model nhỏ fine-tune.

Đ5. Stacking, ensemble và hiệu chỉnh.

- Meta-model (ridge hoặc LightGBM) học trên OOF của B2–B4, Đ1–Đ4 và đặc trưng mức type; so với rank-average đơn giản.
- Hiệu chỉnh tuyến tính (hệ số dương) giữ nguyên cả hai metric xếp hạng và chỉ giảm RMSE; tránh isotonic vì nó tạo điểm hòa.

- Cơ sở: meta-ensemble ở SemEval-2026 Task 5; late fusion (Kurtyigit et al. 2025); thông tin bổ sung giữa các cách tiếp cận (Miletić & Schulte im Walde 2025).

Đ6. (Tùy chọn) Bền vững với văn bản lịch sử.

- Suy đoán thời kỳ của câu băng heuristic chính tả/từ cổ hoặc một classifier nhỏ; dùng để phân tích lỗi và làm đặc trưng.
- Thử chuẩn hóa chính tả cũ và augmentation; đo khoảng cách hiệu năng giữa hai nhóm câu.
- Cơ sở: BTC sẽ phân tích kết quả theo thời kỳ sau evaluation; Jenkins et al. (2026).

Đa phương thức (H9) để ở phần hướng tương lai vì tốn GPU và lợi ích chủ yếu ở compound cụ thể.

7. Thí nghiệm, ablation và phân tích cho paper

Một system paper cần một bảng kết quả chính, khoảng tám ablation và năm đến bảy phân tích; khung dưới đây để nhóm điền dần. Số CV ghi dạng trung bình ± std qua 3 seed × 5 fold; số chính thức lấy từ Codabench.

Bảng kết quả chính (CV, điền dần)

Hệ thống	Mod ρ	Mod var-ρ	Mod RMSE	Head ρ	Head var-ρ	Head RMSE
B0 hằng số / type oracle						
B1 cosine tĩnh						
B2 BERT không giám sát						
B3 DeBERTa fine-tune						
B4 LLM zero-shot						
Đ1 prior + δ						
Đ1 + Đ2						
Đ1 + Đ2 + Đ3						
Đ4 LLM chấm theo nhóm						
Đ5 stacking (bản nộp)						

Ablation

- [ ] Đ1: chỉ p, chỉ δ, và cả hai
- [ ] Đ2: bỏ soft-Spearman; bỏ ranking trong compound

- [ ] Đ2: bỏ trọng số theo bất đồng
- [ ] Đ3: bỏ định nghĩa; bỏ paraphrase; bỏ đặc trưng XL-LEXEME
- [ ] B3/Đ1: DeBERTa base so với large; 1 seed so với 3 seed
- [ ] Đ4: chấm từng câu so với chấm cả nhóm; 0 / 3 / 8 shot
- [ ] Đ5: một model so với ensemble; stacking so với rank-average
- [ ] Có và không có dữ liệu ngoài (NCTTI, Reddy), nếu luật cho phép

Phân tích

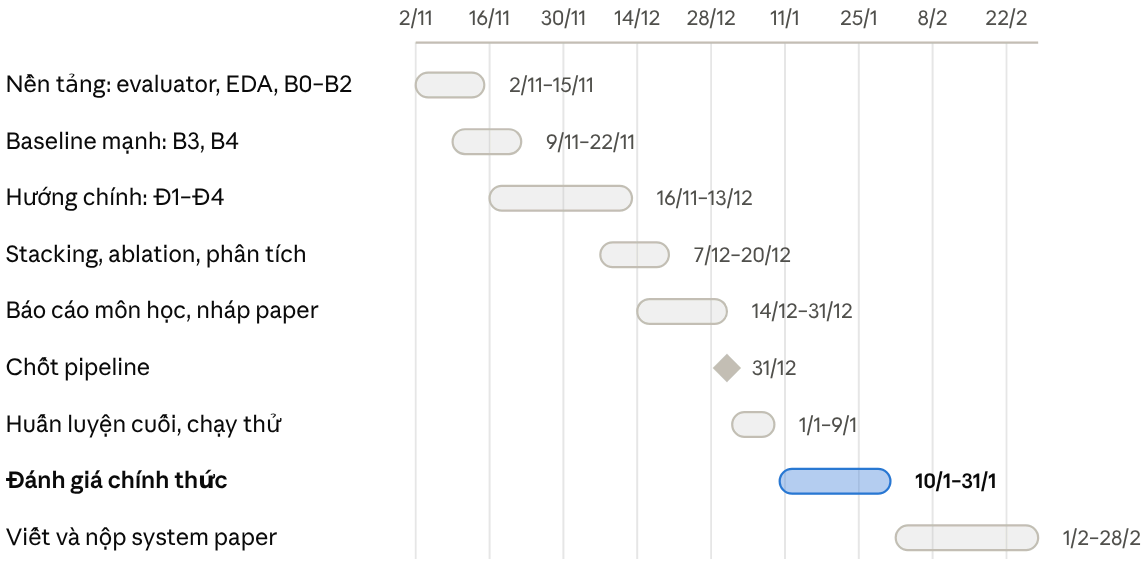
1. Tách metric chính thành phần giữa compound và phần trong compound.
2. Mod so với Head: thành phần nào khó hơn, và ở loại compound nào.
3. Theo nhóm compositional thấp, trung bình, cao.
4. Theo thời kỳ suy đoán: câu hiện đại so với câu lịch sử.
5. Theo tần suất, độ đa nghĩa, độ cụ thể của thành phần; Miletić & Schulte im Walde (2023) thấy các yếu tố này ảnh hưởng đến mô hình.
6. Mức contamination của LLM và ảnh hưởng lên điểm.
7. 10–15 ví dụ lỗi định tính, có giải thích.

8. Lộ trình và phân công

Chốt pipeline trước 31/12/2026 để kịp báo cáo môn học; tháng 1 chỉ huấn luyện lại trên toàn bộ train, nộp bài chính thức và viết paper.

Chốt pipeline 31/12 để tháng 1 chỉ còn đánh giá chính thức và viết paper

Kế hoạch 11/2026 – 2/2027, vạch chia 2 tuần; các giai đoạn được phép chồng lấn



lộ trình 11/2026 – 2/2027 · 8 giai đoạn, 1 mốc chốt

Hạn nộp paper chính xác sẽ do SemEval-2027 công bố; thanh tháng 2 chỉ là khoảng dự kiến. Nếu hạn báo cáo môn học sớm hơn 31/12, dời mốc chốt lên tương ứng.

Đầu ra của từng giai đoạn

1. Nền tảng (2–15/11): đọc 5 paper cốt lõi (Kurtyigit 2025, Miletić 2023, Garcia 2021, khảo sát TACL 2024, Jenkins 2026); viết `evaluator.py`; EDA gồm ICC, phân bố điểm, kiểm tra rò rỉ `ContextID`; cố định bộ chia CV; chạy B0–B2; nộp thử trial.
2. Baseline mạnh (9–22/11): B3 và B4; bảng kết quả đầu tiên.
3. Hướng chính (16/11–13/12): Đ1, Đ2, Đ3, Đ4 và contamination probe.
4. Stacking và ablation (7–20/12): Đ5, các ablation, các phân tích ở mục 7.
5. Báo cáo môn học (14–31/12): báo cáo, slide; nháp Introduction, Related work, System của paper.
6. Huấn luyện cuối (1–9/1/2027): train trên toàn bộ dữ liệu, chạy thử pipeline suy luận, kiểm tra định dạng file nộp.
7. Đánh giá chính thức (10–31/1/2027): nộp dự đoán test; kiểm tra trước số lượt nộp được phép.
8. Paper (tháng 2/2027): thêm kết quả chính thức và phân tích, rồi nộp.

Phân công đề xuất

Mảng	Việc chính	Đầu ra
A. Dữ liệu và đánh giá	Evaluator, CV, EDA, B0–B2, stacking Đ5, nộp bài	`evaluator.py`, kho OOF, file nộp
B. Mô hình encoder	B3, Đ1, Đ2, Đ3	Checkpoint và OOF
C. LLM	B4, Đ4, contamination probe	Điểm LLM và OOF

Khi viết paper, A lo Setup và Results, B lo System, C lo phần LLM và Analysis. Nhóm ít hơn ba người thì gộp mảng A vào B.

Tài nguyên tính toán

- GPU miễn phí 16 GB (Kaggle, Colab) đủ cho DeBERTa-v3-large với fp16 và câu ngắn, và cho LLM 7–9B ở 4-bit.
- LoRA cho model 8B trên một GPU 16 GB chậm; ưu tiên model 3–4B hoặc thuê GPU ngắn hạn khi cần.
- Chi phí API nhỏ vì chỉ khoảng 4.400 câu (3.480 train + 908 test), nhưng phải ghi rõ model và phiên bản trong paper.

9. Dàn ý system description paper

Paper nên kể một câu chuyện: điểm số đến từ cả mức type lẫn mức câu, và mỗi khối của hệ thống nhắm vào một metric cụ thể.

1. **Abstract:** hệ thống, thứ hạng, phát hiện chính trong 4–5 câu.
2. **Introduction:** task, 3–4 đóng góp, thứ hạng chính thức, link code.
3. **Background:** mô tả task và dữ liệu ngắn gọn; related work theo dự đoán compositional (H1–H3), MWE trong transformer (H2) và LLM chấm điểm (H6).
4. **System overview:** hình pipeline; Đ1–Đ5, mỗi khối nói rõ nhắm metric nào.
5. **Experimental setup:** CV, siêu tham số, phần cứng; prompt đầy đủ để ở phụ lục.
6. **Results:** bảng chính thức và bảng CV; ablation.
7. **Analysis:** các phân tích ở mục 7.
8. **Conclusion, Limitations, Ethics, References, Appendix:** hạn chế gồm dữ liệu nhỏ, phụ thuộc LLM, nguy cơ contamination.

Các đóng góp có thể nêu: (1) phân rã type/token và hệ thống hai mức; (2) loss bám metric phụ; (3) bổ sung định nghĩa/WiC; (4) phân tích contamination trên câu lịch sử. Kiểm tra giới hạn trang và template khi SemEval-2027 công bố hướng dẫn system paper, và công khai code trên GitHub.

10. Rủi ro và cách giảm

Rủi ro lớn nhất là overfit trên chỉ 444 compound và vô tình khai thác rò rỉ dữ liệu; cả hai đều phát hiện được sớm nếu theo dõi đúng chỉ số.

Rủi ro	Dấu hiệu	Cách giảm
Overfit vì dữ liệu nhỏ	Điểm CV dao động mạnh giữa các seed	Ensemble nhiều seed, early stopping, thử model base trước
Metric phụ tụt do dự đoán "sập"	Có compound với std dự đoán bằng 0	Theo dõi chỉ số này mỗi lần chạy; thêm ranking trong compound (Đ2)
LLM đã thấy dữ liệu	Điểm cao bất thường trên câu lịch sử	Contamination probe; báo cáo trung thực trong paper
Vô tình dùng rò rỉ `ContextID`	Mô hình phụ thuộc thứ tự dòng	Xáo trộn dữ liệu, không dùng ID; báo BTC nếu xác nhận
Luật về dữ liệu ngoài và LLM chưa rõ	Codabench chưa ghi rõ	Đọc mục Terms trên Codabench; hỏi BTC qua email liên hệ trên trang task
Thiếu GPU	Job bị dừng, hết quota	Ưu tiên model base, lượng tử hóa 4-bit, cache embedding
Lệch hạn môn học và SemEval	Tháng 1 vẫn còn thử nghiệm mới	Chốt pipeline 31/12; tháng 1 chỉ chạy lại và viết

Nguồn

Task

- SemEval-2027 Task 5: ComPartMent — trang task
- Codabench, competition 17971

- Danh sách task SemEval-2027
- Lịch chung SemEval-2027
- Thông báo SemEval-2027 Task 3 (mốc nộp paper cùng đợt)
- Repo công khai của đội khác: bản lưu Overview Codabench, phân tích metric, README và kết quả

Compositionality và MWE

- Reddy, McCarthy & Manandhar (2011). An Empirical Study on Compositionality in Compound Nouns. IJCNLP.
- Salehi, Cook & Baldwin (2015). A Word Embedding Approach to Predicting the Compositionality of Multiword Expressions. NAACL.
- Cordeiro, Villavicencio, Idiart & Ramisch (2019). Unsupervised Compositionality Prediction of Nominal Compounds. Computational Linguistics.
- Shwartz & Dagan (2019). Still a Pain in the Neck: Evaluating Text Representations on Lexical Composition. TACL.
- Dhar, Pagel & van der Plas (2019). Measuring the Compositionality of Noun-Noun Compounds over Time.
- Garcia, Kramer Vieira, Scarton, Idiart & Villavicencio (2021). Assessing the Representations of Idiomaticity in Vector Models with a Noun Compound Dataset Labeled at Type and Token Levels. ACL.
- Tayyar Madabushi et al. (2022). SemEval-2022 Task 2: Multilingual Idiomaticity Detection and Sentence Embedding.
- Miletić & Schulte im Walde (2023). A Systematic Search for Compound Semantics in Pretrained BERT Architectures. EACL.
- Miletić & Schulte im Walde (2024). Semantics of Multiword Expressions in Transformer-Based Models: A Survey. TACL.
- Mahdizadeh Sani et al. (2024). What Can Diachronic Contexts and Topics Tell Us About the Present-Day Compositionality of English Noun Compounds? LREC-COLING.
- Miletić & Schulte im Walde (2025). Modeling the Evolution of English Noun Compounds with Feature-Rich Diachronic Compositionality Prediction. ACL.
- Kurtyigit, Frassinelli, Silberer & Schulte im Walde (2025). A Couch Potato is not a Potato on a Couch. Findings of ACL.
- Godbersen et al. (2026). Fruitcakes and Cupcakes Emerging from Noise: The ComposiGen Dataset. LREC.

- Jenkins, Raimundo Schulz, Miletić & Schulte im Walde (2026). Losing My Composure: Predicting Compositionality Over Time. arXiv.

Phương pháp và task tương tự

- Blondel, Teboul, Berthet & Djolonga (2020). Fast Differentiable Sorting and Ranking. ICML.
- Uma et al. (2021). Learning from Disagreement: A Survey. JAIR.
- Cassotti et al. (2023). XL-LEXEME: WiC Pretrained Model for Cross-Lingual LEXical sEMantic changE. ACL.
- Liu et al. (2023). G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment. EMNLP.
- Gehring, Meyer & Roth (2026). SemEval-2026 Task 5: Rating Plausibility of Word Senses in Ambiguous Stories.
- Islam & Erana (2026). COGNAC at SemEval-2026 Task 5.
- Sumanathilaka et al. (2026). SwanNLP at SemEval-2026 Task 5.